

近邻：相似用户，由近邻相似度指标决定。

近邻相似度指标：衡量两个样本之间相似度的数学量，取值越大代表这两个样本越相似。

CN 相似度

通用邻居(CN)相似度：观察两个样本之间共用的邻居数量来决定它们是否相似，其表达式为：

场景：

- 社交网络好友推荐场景：CN 相似度是用户 x 与用户 y 之间共同好友的数量。
- 短视频推荐场景：CN 相似度是用户 x 与用户 y 都喜欢的短视频数量。

```
def CN(set1, set2):  
    return len(set1 & set2)
```

Jaccard 相似度

Jaccard 指标是在 CN 指标的基础上除以样本间的并集。这样就考虑了样本本身的集合越来越多，对于相似判断的权重就会越低。

且 Jaccard 相似度的取值范围为[0, 1]，越接近 1 则表示越相似。不需要做归一化处理。

Jaccard 表达式为：

```
def Jaccard(set1, set2):  
    return len(set1 & set2)/len(set1 | set2)
```

Cos 相似度

Cos 相似度：两个向量在空间里的夹角余弦值。取值范围为[-1, 1]。

Cos 相似度公式：

即两个向量的内积除以 L2 范数的乘积。

```
def cos4vector(v1, v2):  
    return (np.dot(v1, v2))/(np.linalg.norm(v1) * np.linalg.norm(v2))
```

两个集合间 Cos 相似度的公式:

```
def cos4set(set1, set2):  
    return len(set1 & set2)/(len(set1) * len(set2)) ** 0.5
```

Pearson 相似度

皮尔逊相似度又称为**皮尔逊相关系数**，用于衡量两个变量之间的相关程度。

取值范围为[-1, 1]。1 代表完全相关，0 代表毫无关系，-1 代表完全负相关。基准公式为:

其中， $\text{cov}(X, Y)$ 代表**协方差矩阵**，公式如下:

σ_X 代表 **X 的标准差**:

将上述公式代入皮尔逊相似度可展开为:

```
def pearson(v1, v2):  
    v1_mean = np.mean(v1)  
    v2_mean = np.mean(v2)  
    return (np.dot(v1 - v1_mean, v2 - v2_mean)) / \  
        (np.linalg.norm(v1 - v1_mean) * np.linalg.norm(v2 - v2_mean))
```

Pearson 相似度与 Cos 相似度之间的联系

Pearson 相似度与 Cos 相似度之间存在隐藏关系，Cos 相似度公式展开为:

Pearson 相似度公式可把

所以 Pearson 相似度是先让每个向量的值都减去该向量所有值的平均值，然后求夹角余弦值。

这个操作其实等于先**对数据做标准化的处理**，然后取余弦相似度。

对数据做标准化处理的意义：Pearson 相似度比 Cos 相似度更加合理。

注意：不是所有情况下 Pearson 相似度都优于 Cos 相似度。如果只是求两个集合间的相似度，则 Pearson 相似度无意义。因为 Pearson 相似度更能体现的是数据的线性相关性，假设每个用户对物品的评分具有时间属性，例如用户越早的评分记录在向量中考前的位置，越晚的评分记录在向量中靠后的位置。此时 Pearson 相似度就完美体现出不同用户对物品喜好演化过程的相似度。

```
def pearsonSimple(v1, v2):  
    v1 -= np.mean(v1)  
    v2 -= np.mean(v2)  
    return cos4vector(v1, v2)
```